

ĐỒ ÁN DSP391m — DATA SCIENCE CAPSTONE PROJECT

TÀI LIỆU DÙNG CHUNG

Quy tắc phòng tránh rò rỉ dữ liệu theo thời gian

Hạng mục STT 12 — nền tảng cho làm sạch và trích đặc trưng (Báo cáo 2)

Mã tài liệu	QT-T1-KHOA-N1
Đề tài	Time-Aware Explainable Machine Learning for Early At-Risk Student Prediction on OULAD
Nhóm thực hiện	Nhóm 1 — Sơn, Khoa, An, Đức, Phúc, Bình
Giảng viên hướng dẫn	Nguyễn Thị Hoàng Yến
Phiên bản	1.0
Hạng mục	STT 12 — Làm sạch dữ liệu (văn bản hoá quy tắc phòng tránh rò rỉ)
Phụ thuộc	Biên bản Bước 0 (BB-B0-N1)

1. Mục tiêu và phạm vi

Tài liệu này quy định các quy tắc phòng tránh rò rỉ dữ liệu theo thời gian (*temporal leakage*) áp dụng thống nhất trong toàn bộ đồ án, làm bản tham chiếu chung cho cả nhóm khi trích đặc trưng theo mốc tiến độ (STT 10–13) và làm sạch dữ liệu (STT 12). Quy tắc được suy ra trực tiếp từ Biên bản Bước 0 và phải được tôn trọng ở cả sáu mốc dự đoán 10%, 20%, 40%, 60%, 80% và 100% của độ dài môn học.

Mục tiêu cụ thể: (i) định nghĩa rõ rò rỉ theo thời gian trong bối cảnh dự đoán sớm; (ii) phát biểu **ba quy tắc** loại bỏ dữ liệu tương lai kèm ví dụ minh hoạ; và (iii) chỉ ra cơ chế hiện thực hoá và kiểm chứng tự động để bảo đảm tuân thủ.

2. Định nghĩa rò rỉ theo thời gian

Rò rỉ theo thời gian là việc sử dụng dữ liệu phát sinh *sau* thời điểm dự đoán để huấn luyện hoặc đánh giá mô hình. Hệ quả là mô hình đạt hiệu năng cao giả tạo trong thực nghiệm nhưng không khả dụng khi triển khai, vì tại thời điểm dự đoán thực tế các dữ liệu tương lai đó chưa tồn tại. Trong bài toán dự đoán sớm theo mốc tiến độ (RQ1) [1], mỗi mốc $t\%$ tương ứng một thời điểm dự đoán; mọi sự kiện có ngày vượt ngưỡng ngày của mốc phải bị loại trước khi tính đặc trưng.

3. Mốc tiến độ và ngưỡng ngày theo từng môn–kỳ

Vì mỗi môn–kỳ có độ dài khác nhau, mốc $t\%$ phải được quy đổi sang ngưỡng ngày tuyệt đối **riêng cho từng môn–kỳ** theo công thức `threshold_day = round(module_presentation_length`

$\times t / 100$). Bảng 1 minh họa: cùng mốc 40% nhưng môn dài 240 ngày có ngưỡng 96, còn môn dài 268 ngày có ngưỡng 107 — do đó không thể dùng một ngưỡng ngày chung cho mọi môn.

Bảng 1. Ví dụ quy đổi sáu mốc tiến độ sang ngưỡng ngày cho hai môn có độ dài khác nhau.

Mốc tiến độ t	Ngưỡng ngày — môn dài 240 ngày	Ngưỡng ngày — môn dài 268 ngày
10%	24	27
20%	48	54
40%	96	107
60%	144	161
80%	192	214
100%	240	268

4. Ba quy tắc phòng tránh

Ba quy tắc dưới đây được áp dụng thống nhất cho cả sáu mốc thời gian. Mỗi quy tắc kèm một ví dụ minh họa cách xác định bản ghi cần loại.

Quy tắc 1. Bài đánh giá (assessments). Loại mọi bản ghi trong `studentAssessment` có `date_submitted` vượt ngưỡng ngày của mốc. *Ví dụ minh họa.* Tại mốc 40% của môn dài 240 ngày (ngưỡng 96 ngày), một bài nộp ở ngày 120 bị loại khỏi dữ liệu mốc 40%; chính bài đó lại được giữ ở mốc 60% (ngưỡng 144 ngày).

Quy tắc 2. Tương tác / clickstream (VLE). Loại mọi bản ghi trong `studentVle` có `date` vượt ngưỡng ngày của mốc. Đây là nguồn rò rỉ lớn nhất do `studentVle` chứa xấp xỉ 10 triệu lượt tương tác [2]. *Ví dụ minh họa.* Một lượt click ngày 150 chỉ xuất hiện trong dữ liệu từ mốc 80% trở đi đối với môn dài 240 ngày (ngưỡng 192 ngày); ở các mốc sớm hơn, lượt click này bị loại hoàn toàn.

Quy tắc 3. Sinh viên rút môn (Withdrawn, theo Phương án A). Theo Biên bản Bước 0 (Mục 4.2), sinh viên rút môn **không** bị loại khỏi quần thể tại bất kỳ mốc nào; nhãn at-risk của họ là cố định theo `final_result`. Hàm cắt theo thời gian (STT 11) tự động loại các sự kiện sau ngày rút môn, nên đặc trưng tại mốc t chỉ phản ánh hoạt động tới thời điểm đó. *Ví dụ minh họa.* Một sinh viên rút môn ở ngày 70 vẫn nằm trong dữ liệu mốc 40% và 100%, nhưng mọi tương tác sau ngày 70 không được tính; sự suy giảm hoạt động này là tín hiệu cảnh báo sớm hợp lệ, không phải rò rỉ.

Hạn chế đã ghi nhận của Phương án A. Ở các mốc muộn, sinh viên rút sớm gần như không còn hoạt động nên mô hình dễ phát hiện, có thể khiến recall và PR-AUC lạc quan hơn thực tế.

Nhóm nêu rõ hạn chế này trong báo cáo và sẽ kiểm chứng độ nhạy theo Phương án B (kiểm duyệt quần thể) nếu tiến độ cho phép.

5. Hiện thực hoá và kiểm chứng tự động

Ba quy tắc trên được hiện thực hoá trong hàm `cut_at_checkpoint` (tệp `time_utils.py`, STT 11): hàm gắn ngưỡng ngày theo từng môn-kỳ và chỉ giữ bản ghi có ngày không vượt ngưỡng. Lỗi của quy tắc là biểu thức mặt nạ (*mask*) sau:

```
# Attach the checkpoint day-threshold to each event (by module-presentation key),
# then keep only records that do not exceed it (Rules 1 & 2).
merged = events.merge(thresholds, on=PRESENTATION_KEY, how='left')
within_window = merged['date'].isna() | (merged['date'] <= merged['threshold_day'])
events_cut = merged.loc[within_window]
```

Mã 1. Lỗi chống rò rỉ trong `cut_at_checkpoint` (`time_utils.py`).

Tính tuân thủ được kiểm chứng tự động bởi `test_leakage.py` (STT 14): với mỗi mốc, kiểm thử khẳng định không tồn tại bản ghi vượt ngưỡng; nếu vi phạm, kiểm thử báo `AssertionError` ngay, tránh để sai sót âm thầm lọt vào bước mô hình hoá.

6. Tiêu chí nghiệm thu (Definition of Done)

- Văn bản nêu đủ ba loại rò rỉ và biện pháp phòng tránh tương ứng, kèm ví dụ minh hoạ.
- Quy ước xử lý Withdrawn nhất quán với Phương án A trong Biên bản Bước 0.
- Kiểm thử `test_leakage.py` đạt ở cả sáu mốc (không bản ghi vượt ngưỡng).
- Tài liệu được toàn nhóm thông qua và lưu vào kho dùng chung.

7. Tài liệu liên quan

- Biên bản Bước 0 (BB-B0-N1) — quy ước nhãn (Phương án A) và phạm vi quần thể.
- `time_utils.py` — `build_checkpoint_map` (STT 10) và `cut_at_checkpoint` (STT 11).
- `test_leakage.py` — kiểm thử rò rỉ tự động (STT 14).

Tài liệu tham khảo

- [1] M. Adnan và cộng sự, “Predicting at-Risk Students at Different Percentages of Course Length for Early Intervention Using Machine Learning Models,” *IEEE Access*, vol. 9, pp. 7519–7539, 2021.
- [2] J. Kuzilek, M. Hlosta, và Z. Zdrahal, “Open University Learning Analytics dataset,” *Scientific Data*, vol. 4, art. no. 170171, 2017.