

Dự đoán sớm sinh viên có nguy cơ học tập kém theo thời gian trên OULAD

Đánh giá kép theo quần thể, độ ổn định của giải thích, và độ bền với mất cân bằng lớp


Nhóm 1: T. B. Phúc, P. M. Đức, P. V. Khoa, N. T. Bình, N. V. An, L. Q. T. Sơn

Đại học FPT, Hà Nội • GVHD: Nguyễn Thị Hoàng Yến

Đồ án tốt nghiệp DSP391m

Bài toán: trượt và bỏ học trong học trực tuyến

- Học trực tuyến mất nhiều sinh viên vì **trượt** và **bỏ học**.
- Hỗ trợ muộn không thay đổi kết cục; giáo viên cần biết **ai** và **khi nào**, đủ sớm để can thiệp.
- Và **vì sao** bị gắn cờ, để cảnh báo đáng tin và công bằng.



Sinh viên nguy cơ ngừng hoạt động từ rất sớm trước hạn nộp.

Điểm mấu chốt hầu như không ai kiểm

- Mô hình theo thời gian được chấm ở giữa khóa trên **toàn bộ danh sách ghi danh**.
- Danh sách đó vẫn chứa sinh viên **đã rút**, vốn dễ nhận ra qua sự bất hoạt.
- Nên một phần điểm “cảnh báo sớm” thực chất là **nhận ra một kết cục đã xảy ra rồi**.

Câu hỏi trung tâm

Chúng ta thật ra đang dự đoán ai, và cách chọn quần thể có thời phòng kết quả không?


Câu hỏi.

- RQ1 Mô hình nào tốt nhất, và *sớm đến mức nào* thì tin cậy (recall và $\text{PR-AUC} \geq 0,80$)?
- RQ2 Giải thích (SHAP, LIME) *ổn định* đến đâu?
- RQ3 Xử lý mất cân bằng có quan trọng không, khi at-risk là *đa số* nhẹ (52,8%)?

Đóng góp.

- **Định lượng mức thời phòng do chọn quần thể** (CI khoảng cách loại trừ 0 ở mọi mốc).
- Benchmark theo thời gian **đã kiểm định** (Friedman, Wilcoxon-Holm, 25 CV fit).
- Độ ổn định giải thích so với **mốc ngẫu nhiên Monte-Carlo**, không đánh giá bằng mắt.
- Một **quy tắc báo cáo kép** và dashboard cho giáo viên.

- **32.593** lượt ghi danh, **28.785** sinh viên, **22** module-presentation.
- **7 bảng** từ **3 hệ thống**: thông tin sinh viên, clickstream VLE (~10,6 triệu dòng), chấm bài.
- Nhãn = {Fail, Withdrawn} = **52,8%** (đa số nhẹ, không phải lớp hiếm).
- Snapshot cố định, ẩn danh $\Rightarrow$ tái lập được.



Phương pháp: pipeline chống rò rỉ, theo thời gian

Dữ liệu thô (7 bảng) → **Chia theo sinh viên, đóng băng** → 6 mốc (10–100%) → Đặc trưng
fit trên train → 5 mô hình → SHAP / LIME

- Chia **theo sinh viên**, đóng băng: không sinh viên nào ở cả train lẫn test.
- Tại mốc t , chỉ dùng dữ liệu trước hoặc bằng t (không nhìn trộm tương lai).
- Mọi phép biến đổi, resampler, ngưỡng chỉ **fit trên train**.
- **21 test tự động** bảo vệ pipeline.

Ý tưởng chính: hai câu hỏi, hai quần thể

Toàn bộ quần thể

"Lượt này có kết thúc Fail/Withdrawn?"

- Là cách nghiên cứu trước dùng.
- Gồm cả sinh viên đã rút.

Quần thể còn theo học


"Giáo viên nên liên hệ ai lúc này?"

- Chỉ những sinh viên còn can thiệp được.
- Mới là cảnh báo sớm thật.

Chấm **cùng một dự đoán** trên cả hai, và báo cáo cả hai.

Kết quả 1: mô hình nào, và thứ hạng có thật không?


- **XGBoost** dẫn recall (0,930 cuối khóa); các mô hình cây bám sát nhau.
- Thứ hạng **đã kiểm định**: Friedman ($p < 0,05$) + Wilcoxon-Holm, 25 CV fit.
- Logistic chỉ kém vài điểm $\Rightarrow$ **đặc trưng** mang tín hiệu.



Kết quả 2 (chính): hiệu ứng quần thể

- Toàn bộ quần thể vượt recall $\geq 0,80$ từ $t=40\%$...
- ...nhóm **còn theo học** chỉ vượt ở **cuối khóa**.
- CI khoảng cách **loại trừ 0** ở mọi mốc.

$t=40\%$: 0,811 so với 0,678. $t=100\%$: 0,930 so với 0,841.




Thông điệp

Độ tin cậy cảnh báo sớm phụ thuộc **bạn chấm trên quần thể nào**: 40% trên giấy, nhưng cuối khóa với nhóm sinh viên thật sự can thiệp được.


Kết quả 3: giải thích — đặc trưng dẫn đầu và độ ổn định

- Đặc trưng số 1: **số ngày im lặng VLE**, rồi điểm tích lũy.
- Không có nhân khẩu học ở top $\Rightarrow$ cảnh báo **dựa trên hành vi**, không phải hoàn cảnh.
- **Ổn định**: Jaccard top-10 **0,69** so với mốc ngẫu nhiên **0,12**.
- SHAP và LIME đồng thuận ở đặc trưng dẫn đầu, khác ở đuôi.



Độ bền và các phân tích bổ sung

- **Mất cân bằng:** qua 4 chiến lược, chênh recall tối đa 0,007, kết luận không đổi.
- **Luật nền:** luật 2 đặc trưng thắng XGBoost sớm (sinh viên rút quá dễ) nhưng thua cuối khóa $\Rightarrow$ chính sách **lại**.
- **Hiệu chỉnh** tốt (ECE 0,018 đến 0,042); **5 đặc trưng** bằng mô hình đầy đủ; gap train-test thu hẹp (không overfit).



- **Một dataset**; chưa kiểm chứng khả năng chuyển sang trường khác.
- **Nhãn gộp** Fail (khó) và Withdrawn (dễ, hành vi), tách chúng là bước tiếp theo quan trọng.
- Đặc trưng dẫn đầu một phần là *hệ quả* của việc đã rút, nên điểm toàn phần thể "đọc" kết cục nhiều như dự báo; con số còn theo học (0,841) mới là con số trung thực.
- Ranh giới tại $t=40\%$; phân tích còn-theo-học chấm lại mô hình huấn luyện trên toàn roster.

Thông điệp

- Mô hình cây gradient boosting thắng một benchmark *đã kiểm định*; con số cảnh báo sớm trung thực nằm ở nhóm **còn theo học**.
- Giải thích ổn định và dựa trên hành vi; đặc trưng dẫn đầu *chính là* kênh gây thổi phồng.

Mọi tuyên bố cảnh báo sớm nên nêu rõ quần thể, kèm khoảng bất định, và gắn giải thích với mốc thời gian.

Xin cảm ơn

Câu hỏi ạ?

Pipeline tái lập được, 21 test, dashboard và bài báo đều trong repo.
Mọi hình và số truy được về `reports/tables/*.csv`.

Backup: bảng dual-cohort

t (%)	Toàn bộ	Còn theo học	Khoảng cách
40	0,811 [0,798; 0,824]	0,678 [0,656; 0,698]	0,133 [0,122; 0,144]
60	0,870 [0,859; 0,882]	0,749 [0,730; 0,770]	0,121 [0,110; 0,133]
80	0,897 [0,887; 0,907]	0,779 [0,760; 0,800]	0,118 [0,106; 0,130]
100	0,930 [0,921; 0,939]	0,841 [0,821; 0,861]	0,089 [0,076; 0,101]

CI bootstrap 95% (1.000 resample mức sinh viên).

Backup: hiệu chỉnh và rút gọn đặc trưng

